

UNIVERZITET U BEOGRADU
MATEMATIČKI FAKULTET

Analiza skupa podataka za
prepoznavanje ljudskih aktivnosti
primenom fizioloških signala

Izveštaj

iz:

Istraživanja podataka 2

STUDENT:

Gala Posedi

1067/2025

Beograd, jul 2026.

1 Uvod

U ovom seminarskom radu korišćen je javno dostupan skup podataka koji sadrži fiziološka merenja prikupljena sa ciljem automatskog prepoznavanja vrste aktivnosti čoveka. Podaci su prikupljeni od **40 ispitanika** starosti između 20 i 49 godina (12 žena i 28 muškaraca), pri čemu je svaki ispitanik bio izložen četiri različite vrste aktivnosti: **1-neutralnoj (odmor)**, **2-mentalnoj**, **3-emocionalnoj** i **4-fizičkoj aktivnosti**. Eksperiment je trajao približno 90 minuta po ispitaniku.

Tokom eksperimenta mereni su fiziološki signali **elektrokardiograma (ECG)**, **torakalne električne bioimpedance (TEB)** i **elektrodermalne aktivnosti (EDA)** pomoću nosivih senzora. Na osnovu ovih signala izračunat je veliki broj karakteristika (feature-a) u vremenskom i frekvencijskom domenu, uključujući različite statističke pokazatelje, parametre varijabilnosti srčanog ritma, energetske karakteristike, kao i druge srodne osobine. Na taj način dobijeno je ukupno **533 prediktora**, dok ciljna promenljiva **Activity** označava jednu od četiri posmatrane aktivnosti.

Formiranje velikog broja prediktora predstavlja rezultat postupka ekstrakcije karakteristika iz originalnih fizioloških signala, jer se smatra da se iz prethodno navedena tri glavna atributa mogu izvući i druge brojne informacije. Budući da različite karakteristike opisuju različite aspekte istog signala, očekuje se da među njima postoji značajna međusobna korelacija i određeni stepen redundantnosti, što će se kasnije u radu ispitati.

Cilj ovog seminarskog rada jeste naći koji tačno skup karakteristika feature-a daje najbolje rezultate u prepoznavanju stepena aktivnosti kojoj je ispitanik izložen. Zato će se, primenom različitih metoda i algoritama, u daljem radu izdvojiti finalni najbolji skup za svaki od metoda.


2 Preprocesiranje

Na samom početku, učit ćemo podatke iz .csv fajla gde se nalaze podaci o potrebnim prediktorima, a prediktore (labels) ćemo učitati preko funkcije .strip jer poslednji red, koji objašnjava kako se čita prediktor Activity, pa ga csv fajl ne može prepoznati. Labels nije napisan u formatu standardne tabele, već u formatu običnog tekstualnog fajla.

Analizom tipova podataka ustanovljeno je da su svi atributi numeričkog tipa (int64 ili float64). Ciljna promenljiva Activity već je predstavljena numerički i identifikuje četiri klase aktivnosti, pa nije bilo potrebe za dodatnim kodiranjem (encoding-om). Kolona Subject Index se izbacuje iz baze, jer predstavlja samo redni broj ispitanika, a može uticati na performanse i procene međusobnih veza između atributa.

Proverava se i da li postoje nedostajuće vrednosti, kao i duplikati, i ukoliko ih ima, uklanjamo ih iz baze.


Pre implementacije modela izvršena je obrada podataka koja je obuhvatila analizu kvaliteta skupa podataka, standardizaciju atributa, redukciju dimenzionalnosti analizom glavnih komponenti (PCA).



Slika 1: PCA projekcija skupa podataka.

Vidi se sa slike da je 61 prediktor dovoljan i da objašnjava dovoljno varijanse modela.

Vizuelizacija podataka je izvršena pomoću t-SNE algoritma, kao i selekciju najinformativnijih atributa. Ovi koraci imaju za cilj smanjenje dimenzionalnosti, uklanjanje redundantnih informacija i poboljšanje performansi modela mašinskog učenja.



Slika 2: t-SNE vizuelizacija

Na osnovu dobijenih grafika može se uočiti da obe metode omogućavaju izdvajanje četvrte klase, dok se druga i treća klasa značajno preklapaju. Projekcija nakon PCA pokazuje nešto kompaktnije klastere, posebno za prvu klasu, što ukazuje da PCA uspešnije zadržava strukturu podataka nakon redukcije dimenzionalnosti. Međutim, konačnu procenu kvaliteta nije moguće doneti isključivo na osnovu t-SNE vizualizacije, već je potrebno uporediti performanse klasifikacionih modela na oba skupa podataka.


3 Klasifikacija

Za klasifikaciju target-a odabrano je pet algoritama različite složenosti i principa rada. Prva je logistička regresija, koja se koristi kao bazni linearni klasifikacioni model, SVM kao metoda pogodna za nelinearne granice odlučivanja, Random Forest kao predstavnik bagging ensemble metoda, dok AdaBoost i XGBoost predstavljaju dve boosting metode različite generacije. Poređenjem njihovih performansi moguće je analizirati da li naprednije ensemble metode ostvaruju bolje rezultate u klasifikaciji fizioloških signala u odnosu na jednostavnije klasifikatore, da li su linearni metodi pogodniji od nelinearnih, kao i da li savremeniji boosting algoritmi, poput XGBoost-a, donose poboljšanja u odnosu na klasični AdaBoost. Nad svakom metodom je izvršeno testiranje nad celim skupom podataka, kao i nad skupom prediktora dobijenim PCA redukcijom. Implementirana je i matrica konfuzije za svaku implementiranu metodu.

3.1 Logistička regresija

Kako postoje četiri vrste klase target promenljive Activity, koristićemo polinomijalnu logističku regresiju koja procenjuje verovatnoće pripadanja različitim klasama, i bira onu klasu čija je verovatnoća pripadanja najveća. Prvo ćemo svaki algoritam primeniti nad celim skupom podataka, pa onda nad skupom dobijenim PCA metodom. Logistička regresija nad svim prediktorima ostvarila je tačnost klasifikacije od 87.28%, pri čemu su vrednosti precision, recall i F1-score takođe približno 0.87, što ukazuje na stabilne performanse modela.

Logistička regresija nad PCA izabranim prediktorima ostvarila je nešto manju tačnost klasifikacije, oko 81%, pri čemu su vrednosti precision, recall i F1-score dosta slične, što ukazuje na stabilne performanse modela.



Slika 3: Matrica konfuzije Logistička regresija


Poređenjem konfuzionih matrica može se uočiti da model treniran na svim atributima ostvaruje bolje performanse u odnosu na model nakon selekcije atributa. Nakon redukcije broja prediktora povećava se broj pogrešno klasifikovanih uzoraka, naročito između klasa 2 i 3, što ukazuje da su pojedini odbačeni atri-

buti sadržali diskriminativne informacije važne za razlikovanje ovih klasa. Iako selekcija atributa doprinosi smanjenju dimenzionalnosti i može povećati jednostavnost modela, u ovom slučaju je dovela do blagog gubitka informacija, zbog čega je došlo do pada tačnosti klasifikacije. Sa druge strane, klasa 4 ostaje gotovo u potpunosti pravilno klasifikovana, što ukazuje da njene karakteristike ostaju dovoljno izražene i nakon redukcije skupa atributa. Ovakav rezultat je u skladu sa prethodnom analizom podataka, koja je pokazala da su mnogi prediktori međusobno visoko korelisani. Zbog toga je uklanjanje redundantnih atributa doprinelo formiranju jednostavnijeg i robusnijeg modela, uz zanemarljiv pad tačnosti. Takav model je manje podložan overfitting-u i može pružiti pouzdane rezultate prilikom primene na novim podacima.

3.2 Random Forest i SVM algoritam

Upoređujući performanse dobijene SVM algoritmom, i imajući u vidu da su korišćeni prediktori već predstavljali izvedene statističke karakteristike fizioloških signala, među njima je postojala izražena međusobna korelacija i značajna redundantna informacija. Zbog toga primena PCA nije dovela do značajnog poboljšanja performansi SVM modela, već su rezultati ostali veoma slični, što ukazuje da je većina diskriminativnih informacija bila sadržana i u originalnom skupu atributa.

Za razliku od SVM modela, kod Random Forest algoritma primena PCA dovela je do uočljivijeg smanjenja performansi. Ovakav rezultat ukazuje da Random Forest efikasnije iskorišćava informacije sadržane u originalnim atributima, dok linearne kombinacije dobijene PCA transformacijom ne zadržavaju u potpunosti karakteristike koje su najpogodnije za grananje stabala odlučivanja. Takođe, Random Forest model mnogo bolje klasifikuje klase, sa performansama preko 95% za prvi skup, odnosno preko 87% za drugi, što je i očekivano zbog prirode modela i njegovog funkcionisanja.




Slika 4: Matrica konfuzije RandomForest model

3.3 AdaBoost i XGBoost algoritam

Za razliku od prethodnih modela, AdaBoost gradi niz jednostavnih klasifikatora pri čemu svaki naredni model posvećuje veću pažnju uzorcima koji su prethodno bili pogrešno klasifikovani, sa ciljem postepenog poboljšanja ukupne tačnosti klasifikacije.

Ovde su performanse značajno opale, za prvi skup su sve metrike oko 0.75, dok su za PCA skup vrednosti oko 0.72, što govori o tome da AdaBoost algoritam ne procenjuje dobro klase na nivou na kom su to radile prethodne metode. Jedan od razloga može biti to da AdaBoost gradi ansambl velikog broja plitkih stabala koja prvenstveno ispravljaju greške prethodnih modela, ali pri tome teže hvataju složenije nelinearne odnose između velikog broja međusobno povezanih prediktora. Zato ćemo implementirati XGBoost algoritam, gde se očekuje će ostvariti bolje rezultate zahvaljujući optimizovanjem procesu učenja, mogućnosti regularizacije i efikasnijem modelovanju složenih nelinearnih odnosa između prediktora.



Slika 5: Matrica konfuzije RandomForest model


Rezultati pokazuju da je XGBoost ostvario veoma visoke performanse na skupu sa svim prediktorima. Nakon primene PCA uočava se očekivani pad performansi, ali model i dalje zadržava visok nivo tačnosti, što ukazuje da je najveći deo informacija relevantnih za klasifikaciju sačuvan i nakon redukcije dimenzionalnosti. U poređenju sa AdaBoost algoritmom, XGBoost pokazuje znatno bolju sposobnost modelovanja složenih odnosa između prediktora, što potvrđuje njegovu veću efikasnost na ovom skupu podataka.

4 Klasterovanje

Na osnovu svih evaluacionih metrika može se zaključiti da je KMeans++ ostvario najbolje performanse, jer je dao najveću vrednost Silhouette koeficijenta i Calinski–Harabasz indeksa, kao i najmanju vrednost Davies–Bouldin indeksa. Silhouette koeficijent meri koliko je svaki objekat sličan objektima unutar sopstvenog klastera u odnosu na objekte iz drugih klastera, pri čemu veće vrednosti ukazuju na kompaktnije i bolje razdvojene klastere. Calinski–Harabasz indeks

predstavlja odnos između varijanse između klastera i varijanse unutar klastera, pa veće vrednosti ukazuju na bolje definisanu strukturu klastera. Sa druge strane, Davies–Bouldin indeks procenjuje prosečnu sličnost između najbližih klastera, pri čemu su manje vrednosti poželjne jer ukazuju na veću međusobnu razdvojenost klastera.


Hierarchical KMeans je pokazao vrlo slične rezultate, što potvrđuje da su centroidne metode najpogodnije za ovaj skup podataka. Nasuprot tome, algoritmi zasnovani na gustini (DBSCAN, HDBSCAN i OPTICS) nisu bili uspešni, što se može objasniti velikom dimenzionalnošću i karakteristikama skupa podataka, zbog kojih gustina uzoraka nije dovoljno izražena za efikasno formiranje klastera.



Slika 6: UMAP vizuelizacija svi prediktori

Slabije performanse algoritama zasnovanih na gustini mogu se objasniti karakteristikama analiziranog skupa podataka. Skup sadrži veliki broj međusobno korelisanih prediktora, zbog čega u prostoru visokih dimenzija lokalna gustina postaje teško razlikovljiva, što otežava formiranje klastera primenom DBSCAN, HDBSCAN i OPTICS algoritama. Sa druge strane, KMeans++ i Hierarchical KMeans uspešno identifikuju grupe oko njihovih centroida, što ukazuje da podaci imaju strukturu koja više odgovara centroidnim nego gustinskim metodama klasterizacije.

UMAP implementiran nad PCA prediktorima jasno pokazuje zašto su centroidne metode efikasnije:



Slika 7: UMAP vizuelizacija PCA prediktori

Dobijeni rezultati su u skladu sa analizom sprovedenom na skupu sa svim prediktorima, pri čemu su KMeans++ i hijerarhijsko klasterovanje ponovo ostvarili najbolje vrednosti evaluacionih metrika. Nakon primene PCA redukcije dimenzionalnosti razlike između centroidnih i gustinskih metoda postale su još izraženije. PCA formira kompaktnije grupe oko njihovih centara, što odgovara algoritmima zasnovanim na centroidima. Nasuprot tome, algoritmi zasnovani na gustini (DBSCAN, HDBSCAN i OPTICS) nisu uspeli da identifikuju stabilne

klastere, što ukazuje da podaci ni nakon redukcije dimenzionalnosti ne poseduju dovoljno izraženu lokalnu gustinu za njihovu uspešnu primenu.

5 Pravila pridruživanja

U analizi pravila pridruživanja korišćeni su samo algoritmi Apriori i FP-Growth, jer oni predstavljaju najčešće primenjivane i metodološki različite pristupe ovom problemu. Dodatni algoritmi uglavnom pronalaze slična pravila, pa bi njihova primena donela ograničene nove informacije, uz veću računarsku složenost i otežanu interpretaciju rezultata.

5.1 Apriori algoritam

Primena Apriori algoritma na PCA transformisanim podacima rezultovala je manjim brojem, ali kvalitetnijih pravila pridruživanja. Dobijena pravila ostvaruju visoke vrednosti poverenja (confidence) i lift-a, što potvrđuje postojanje značajne povezanosti između pojedinih glavnih komponenti i određenih klasa aktivnosti. Ovakvi rezultati pokazuju da Apriori može uspešno identifikovati najizraženije obrasce u redukovanom prostoru karakteristika, uz znatno jednostavniju interpretaciju u odnosu na primenu nad originalnim skupom od 533 prediktora.

5.2 FP-Growth algoritam

FP-Growth algoritam identifikovao je ista pravila pridruživanja kao i Apriori algoritam, što je očekivano budući da oba algoritma pronalaze iste česte skupove stavki kada se koriste identični pragovi za support i ostali parametri. Razlika između algoritama ogleda se prvenstveno u načinu pretrage prostora mogućih skupova, pri čemu FP-Growth koristi FP-stablo i izbegava generisanje kandidata, što ga čini računarski efikasnijim na većim skupovima podataka.