

UNIVERZITET U BEOGRADU
MATEMATICKI FAKULTET

Analiza skupa podataka za prepoznavanje
ljudskih aktivnosti primenom fizioloških
signala

Izveštaj

iz:

Istraživanja podataka 2

STUDENT:
Gala Posedi
1067/2025

Beograd, jul 2026.

1 Uvod

U ovom seminarskom radu korišćen je javno dostupan skup podataka koji sadrži fiziološka merenja prikupljena sa ciljem automatskog prepoznavanja vrste aktivnosti čoveka. Podaci su prikupljeni od **40 ispitanika** starosti između 20 i 49 godina (12 žena i 28 muškaraca), pri čemu je svaki ispitanik bio izložen četiri različite vrste aktivnosti: **1 – neutralnoj (odmor)**, **2 – mentalnoj**, **3 – emocionalnoj** i **4 – fizičkoj aktivnosti**. Eksperiment je trajao približno 90 minuta po ispitaniku.

Tokom eksperimenta mereni su fiziološki signali **elektrokardiograma (ECG)**, **torakalne električne bioimpedance (TEB)** i **elektrodermalne aktivnosti (EDA)** pomoću nosivih senzora. Na osnovu ovih signala izračunat je veliki broj karakteristika (feature-a) u vremenskom i frekvencijskom domenu, uključujući različite statističke pokazatelje (srednja vrednost, standardna devijacija, percentili), parametre varijabilnosti srčanog ritma (HRV), energetske/spektralne karakteristike (PSD u različitim frekvencijskim opsezima – VLF, LF, MF), kao i druge srodne osobine. Nakon učitavanja baza sadrži **535 kolona** (534 prediktora i target promenljiva Activity), a nakon izbacivanja indeksa ispitanika ostaje **533 prediktora** nad **4480 uzoraka**, pri čemu je svaka od četiri klase Activity ravnomerno zastupljena sa po **1120 uzoraka**. Ova balansiranoost je bitna jer opravdava korišćenje accuracy metrike bez rizika da rezultat bude zavaravajući usled dominacije jedne klase.

Formiranje velikog broja prediktora predstavlja rezultat postupka ekstrakcije karakteristika iz originalnih fizioloških signala, jer se smatra da se iz prethodno navedena tri glavna atributa mogu izvući i druge brojne informacije. Budući da različite karakteristike opisuju različite aspekte istog signala, očekuje se da među njima postoji značajna međusobna korelacija i određeni stepen redundantnosti, što će se kasnije u radu i potvrditi i kvantifikovati.

Cilj ovog seminarskog rada jeste naći koji tačno skup karakteristika daje najbolje rezultate u prepoznavanju stepena aktivnosti kojoj je ispitanik izložen, kao i da li algoritmi klasterovanja mogu bez nadzora (unsupervised) da otkriju tu istu strukturu od četiri grupe. Zato će se, primenom različitih metoda i algoritama – klasifikacije, klasterovanja i pravila pridruživanja – u daljem radu izdvojiti finalni najbolji pristup za svaki od metoda, uz obrazloženje matematičke pozadine zašto se pojedini modeli bolje ili lošije snalaze na ovom tipu podataka.

2 Preprocesiranje

Na samom početku, podaci su učitani iz .csv fajla u kome se nalaze vrednosti svih 533 prediktora, dok su nazivi kolona (labels) učitani zasebno preko funkcije `.strip`, jer poslednji red originalnog opisnog fajla objašnjava kako se čita target promenljiva Activity, pa ga standardni CSV parser ne prepoznaje kao deo tabele.

Kako su autori originalnog skupa podataka zadržali ista imena kolona za merenja koja fizički predstavljaju različite stvari (npr. negde je EDA merena na ruci, negde na podlaktici, ali oznaka u nazivu kolone nije to eksplicitno naznačila), bilo je neophodno preimenovati duplirane nazive kolona pre bilo kakve dalje analize – u suprotnom bi se ozbiljno iskrivili svi dalji rezultati.

Analizom tipova podataka ustanovljeno je da su svi atributi numeričkog tipa (`int64` ili `float64`). Baza ima dimenzije 4480×535 . Ciljna promenljiva Activity već je predstavljena numerički i identifikuje četiri klase aktivnosti, pa nije bilo potrebe za dodatnim kodiranjem (encoding-om). Kolona Subject index (1–40) izbačena je iz baze, jer predstavlja samo redni broj ispitanika i ne nosi fiziološku informaciju – njeno zadržavanje bi moglo veštački uticati na performanse algoritama.

Proverom je utvrđeno da baza ne sadrži nedostajuće vrednosti niti duplirane redove, tako da nije bilo potrebe za imputacijom ili dodatnim čišćenjem podataka na ovom nivou.

2.1 Redukcija početnog skupa podataka

S obzirom na to da skup podataka sadrži veliki broj prediktora dobijenih iz svega tri fiziološka signala (ECG, IT i EDA), očekuje se postojanje značajne međusobne korelacije između njih. Zbog toga je izvršena redukcija baze na dva načina: najpre primenom Pirsonovog koeficijenta korelacije, a potom i pomoću redukcije dimenzionalnosti analizom glavnih komponenti (PCA).

Pirsonov filter. Za svaki par prediktora X_i, X_j izračunat je Pirsonov koeficijent korelacije

$$r_{ij} = \frac{\sum_{k=1}^n (x_{ki} - \bar{x}_i)(x_{kj} - \bar{x}_j)}{\sqrt{\sum_{k=1}^n (x_{ki} - \bar{x}_i)^2} \sqrt{\sum_{k=1}^n (x_{kj} - \bar{x}_j)^2}},$$


a zatim je iz gornjeg trougla korelacione matrice (bez dijagonale) izdvojen za svaki atribut najveći $|r_{ij}|$ sa bilo kojim drugim, preostalim atributom. Ukoliko je $|r_{ij}| > 0.8$, jedan od para atributa je izbačen. Primenom ovog filtera odbačeno je **430 od 533** atributa (preko 80% prediktora), tako da je posle Pirsonove redukcije ostalo **103 atributa**. Ovako drastičan procenat odbačenih atributa je snažna potvrda inicijalne pretpostavke – veći deo od 533 "karakteristika" zapravo predstavlja gotovo linearno zavisne transformacije istih osnovnih signala.

PCA. Pre primene PCA, podaci su standardizovani (korišćenjem `StandardScaler` funkcije) ovo je neophodno za PCA jer maksimizuje disperziju duž novih osa, pa bi bez standardizacije atributi sa prirodno većim opsegom vrednosti dominirali nad atributima manjeg opsega, iako nisu nužno informativniji.

Matematički, PCA traži ortonormiranu bazu $\{v_1, \dots, v_p\}$ sopstvenih vektora kovarijacione matrice $\Sigma = \frac{1}{n-1} X^T X$ (gde je X standardizovana matrica podataka), takvu da svaki naredni pravac v_k maksimizuje preostalu varijansu:

$$v_1 = \arg \max_{\|v\|=1} \text{Var}(Xv), \quad v_k = \arg \max_{\|v\|=1, v \perp v_1, \dots, v_{k-1}} \text{Var}(Xv).$$

Primenom PCA sa kriterijumom zadržavanja 95% kumulativne disperzije dobijeno je da je dovoljno **61 glavna komponenta**, što je prikazano na Slici 1. Svega $\sim 11\%$ originalnog broja atributa je ostalo, i ponovo se potvrđuje da je efektivna dimenzionalnost prostora prediktora znatno manja od nominalne – najveći deo varijabilnosti signala je koncentrisan u relativno malom broju "pravaca" u prostoru karakteristika.



Slika 1: Kumulativna objašnjena varijansa u zavisnosti od broja glavnih komponenti

Interpretacija loading-a glavnih komponenti. Analizom koeficijenata (loading-a) prvih pet komponenti dobijeno je da je PC1, koja objašnjava najveći udeo disperzije, gotovo isključivo određena ECG karakteristikama varijabilnosti srčanog ritma (`ECG_hrv_std`, `ECG_PSD_mad`, `ECG_hrv_mad`, `ECG_PSD_mean`), i to sa skoro identičnim koeficijentima (≈ 0.086 za svaki od navedenih atributa) – ovo direktno potvrđuje da su te ECG karakteristike međusobno gotovo kolinearne i predstavljaju dominantan izvor varijabilnosti u celom prostoru prediktora. Slično, PC2, PC3 i PC5 su dominantno određene karakteristikama torakalne bioimpedance (IT signal – LF, PSD i `p_Total` energetske komponente), dok je PC4 određena EDA karakteristikama (`EDA_Functionals_power_Fil12*`).


Važno je naglasiti da je PCA nenadgledana (unsupervised) metoda i nema informaciju o ciljnoj promenljivoj Activity, pa se iz redosleda komponenti ne može direktno zaključiti koji signal najbolje *razlikuje* tipove aktivnosti.

2.2 Vizuelizacija pomoću t-SNE

Za dvodimenzionalnu vizuelizaciju strukture podataka korišćen je t-SNE (t-distributed Stochastic Neighbor Embedding) algoritam, primenjen kako nad skupom dobijenim Pirsonovim filterom (103 atributa), tako i nad PCA skupom (61 komponenta). Za razliku od PCA, koja je linearna metoda redukcije dimenzionalnosti, t-SNE je nelinearna metoda koja pokušava da u niže-dimenzionom prostoru sačuva lokalnu strukturu suseda – za svaki par tačaka i, j u originalnom prostoru definiše se uslovna verovatnoća

$$p_{j|i} = \frac{\exp(-\|x_i - x_j\|^2 / 2\sigma_i^2)}{\sum_{k \neq i} \exp(-\|x_i - x_k\|^2 / 2\sigma_i^2)},$$

a u prostoru niže dimenzije koristi se Studentova t-raspodela sa jednim stepenom slobode (Koši raspodela).



Slika 2: t-SNE vizuelizacija nakon Pirsonovog filtera (levo) i nakon PCA redukcije (desno), obojeno po klasi Activity.

Na osnovu dobijenih grafika (Slika 2) može se uočiti da obe metode omogućavaju jasno izdvajanje četvrte klase (fizička aktivnost), dok se druga i treća klasa (mentalna i emocionalna aktivnost) značajno preklapaju. Ovo je fiziološki očekivano – mentalni i emocionalni stres izazivaju slične autonomne odgovore u ECG i EDA signalima (povišen otkucaj srca, promene provodljivosti kože usled simpatičke aktivacije), dok fizička aktivnost ima jasno drugačije, mehanički uslovljene fiziološke simptome (znatno veća varijabilnost respiratornog i EKG signala usled fizičkog napora), pa se lakše izdvaja u prostoru karakteristika.

Projekcija nakon PCA pokazuje nešto kompaktnije klastere, posebno za prvu klasu, što ukazuje da PCA uspešnije zadržava globalnu strukturu podataka nakon redukcije dimenzionalnosti u odnosu na Pirsonov filter. Ovo je razumljivo jer PCA komponente predstavljaju optimalne linearne kombinacije svih originalnih atributa, dok Pirsonov filter samo uklanja redundantne attribute pojedinačno. Ipak, konačnu procenu kvaliteta nije moguće doneti isključivo na osnovu t-SNE vizualizacije, već je potrebno uporediti stvarne performanse klasifikacionih modela na oba skupa podataka.

3 Klasifikacija

Za klasifikaciju ciljne promenljive Activity odabrano je pet algoritama: logistička regresija kao bazni linearni klasifikacioni model, SVM (sa Gausovim jezgrom) kao metoda pogodna za nelinearne

granice odlučivanja, Random Forest kao predstavnik bagging ansambl metoda, te AdaBoost i XGBoost kao dve boosting metode različite generacije. Svaki model je treniran i evaluiran nad dva skupa prediktora – nad svim originalnim standardizovanim atributima (533 prediktora) i nad skupom dobijenim PCA redukcijom (61 komponenta, 95% objašnjene varijanse) – korišćenjem podele 70%/30% na trening i test skup, uz stratifikaciju po klasama (`stratify=y`) kako bi svaki skup zadržao ravnomernu zastupljenost sve četiri klase.

Kako su sve četiri klase target promenljive podjednako zastupljene (po 1120 uzoraka svaka), za evaluaciju je korišćen accuracy kao osnovna mera, ali i precision, recall i F1-score računati sa "weighted" usrednjavanjem, čime se obezbeđuje da nijedna klasa ne bude zanemarena prilikom ocene modela. Implementirana je i matrica konfuzije za svaki model.

3.1 Logistička regresija


Kako postoje četiri klase target promenljive Activity, korišćena je polinomijalna logistička regresija, koja za svaku klasu k procenjuje verovatnoću pripadanja preko softmax funkcije:

$$P(y = k | x) = \frac{\exp(w_k^\top x + b_k)}{\sum_{j=1}^4 \exp(w_j^\top x + b_j)},$$

a model bira klasu sa najvećom procenjenom verovatnoćom. Parametri w_k, b_k se ocenjuju maksimizacijom log-verodostojnosti preko `lbfgs` optimizacionog algoritma.

Logistička regresija nad svim prediktorima ostvarila je tačnost klasifikacije od **87.28%**, pri čemu su vrednosti precision (0.8729), recall (0.8728) i F1-score (0.8728) gotovo identične tačnosti, što ukazuje na stabilne i ujednačene performanse modela po svim klasama.

Logistička regresija nad PCA izabranim prediktorima ostvarila je nešto manju tačnost klasifikacije, **81.32%**, uz slično ujednačene vrednosti precision (0.8154), recall (0.8132) i F1-score (0.8142).



Slika 3: Matrice konfuzije za logističku regresiju – nad svim atributima (levo) i nakon PCA (desno).


Poređenjem konfuzionih matrica (Slika 3) može se uočiti da model treniran na svim atributima ostvaruje bolje performanse u odnosu na model nakon PCA redukcije. Nakon redukcije broja prediktora povećava se broj pogrešno klasifikovanih uzoraka, naročito između klasa 2 – što je u potpunosti u skladu sa t-SNE vizuelizacijom iz prethodne sekcije, gde su se baš te dve klase najviše preklapale. Ovo ukazuje da su pojedini atributi odbačeni PCA transformacijom sadržali diskriminativne informacije važne baš za razlikovanje ove dve klase – to jest, deo varijanse koji je PCA odbacio očigledno nije bio šum, već koristan signal za klasifikaciju.

Kod linearnog modela kao što je logistička regresija, redundantni, visoko korelisani atributi generalno ne unose mnogo nove informacije, pa bi njihovo uklanjanje trebalo da ima relativno blag uticaj na performanse modela – što se i pokazalo (pad od svega 6 posto).

3.2 SVM model

SVM (Support Vector Machine) sa Gausovim jezgrom $K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2)$ implicitno projektuje podatke u prostor beskonačne dimenzije u kome traži hiperravan maksimalne margine između klasa. Za razliku od logističke regresije, SVM sa nelinearnim jezgrom omogućava zakrivljene granice odlučivanja u originalnom prostoru atributa.

SVM nad svim atributima postiže Accuracy od **84.30%** (precision 0.8471, recall 0.8430, F1 0.8437), dok SVM nad PCA skupom postiže Accuracy od **83.11%** (precision 0.8372, recall 0.8311, F1 0.8325).




Slika 4: Matrice konfuzije za SVM – nad svim atributima (levo) i nakon PCA (desno).

Upoređujući performanse dobijene SVM algoritmom, primena PCA nije dovela do značajnog pada performansi SVM modela – rezultati su ostali veoma slični (84.30% naspram 83.11%), što ukazuje da je većina diskriminativnih informacija bila sadržana i u originalnom skupu atributa, i da Gausovo jezgro uspeva da rekonstruiše sličnu geometriju granice odlučivanja bez obzira na to da li radi nad 533 originalna atributa ili nad 61 njihovom linearnom kombinacijom. Zanimljivo, SVM nad PCA skupom (83.11%) čak nadmašuje logističku regresiju nad istim skupom (81.32%), što ukazuje da granice između klasa 2 i 3 (mentalna i emocionalna aktivnost) nisu čisto linearne, jer fiziološki signali (ECG, EDA, TEB) često imaju nelinearne zavisnosti sa tipom aktivnosti.

3.3 Random Forest model

Random Forest je ansambl (bagging) algoritam koji gradi veliki broj stabala odlučivanja, svako na drugačijem butstrep uzorku podataka i sa nasumičnom podgrupom atributa u svakom čvoru, a zatim klasifikaciju vrši glasanjem svih stabala. Ovakav pristup smanjuje disperziju modela u odnosu na pojedinačno stablo, jer se greške nezavisnih stabala delimično poništavaju usrednjavanjem, dok svako pojedinačno stablo prilikom podele čvora bira prag jedne promenljive koji najviše smanjuje nečistoću (npr. Gini indeks $G = \sum_k p_k(1 - p_k)$, gde je p_k udeo klase k u datom čvoru).

Random Forest je korišćen sa `n_estimators=100` i `max_depth=10`. Nad svim atributima ostvarena je Accuracy od **95.83%** (precision 0.9593, recall 0.9583, F1 0.9585). Nad PCA skupom Accuracy pada na **87.20%** (precision 0.8745, recall 0.8720, F1 0.8723).



Slika 5: Matrice konfuzije za Random Forest – nad svim atributima (levo) i nakon PCA (desno).

Za razliku od SVM modela, kod Random Forest algoritma primena PCA dovela je do znatno izraženijeg pada performansi – sa 95.83% na 87.20%. Ovakav rezultat ukazuje da Random Forest mnogo efikasnije iskorišćava informacije sadržane u originalnim, nekombinovanim atributima. Razlog leži u samoj prirodi stabla odlučivanja: svaki čvor pravi odluku na osnovu praga *jedne* promenljive (npr. da li je `ECG_RR_window_mean > x`), pa mu pojedinačni, interpretabilni originalni atributi omogućavaju da pronađe jasne, "prirodne" podele prostora karakteristika. Ovo objašnjava zašto su modeli zasnovani na stablima (Random Forest, a kasnije i XGBoost) osetljiviji na PCA transformaciju od modela poput logističke regresije i SVM-a, koji kombinuju informaciju iz svih prediktora istovremeno kroz težinske koeficijente, pa im ne smeta što je informacija linearno raspoređena komponentama.

3.4 AdaBoost algoritam

Za razliku od Random Forest-a, AdaBoost (Adaptive Boosting) je sekvencijalni ansambl algoritam koji gradi niz slabih klasifikatora $h_1, h_2, \dots, h_T$ jedan za drugim, pri čemu svaki naredni model h_t dobija veću težinu na uzorcima koje su prethodni modeli pogrešno klasifikovali. Konačna predikcija je ponderisano glasanje $H(x) = \text{sign}(\sum_t \alpha_t h_t(x))$, gde je $\alpha_t = \frac{1}{2} \ln \frac{1-\epsilon_t}{\epsilon_t}$ težina t -tog klasifikatora obrnuto proporcionalna njegovoj grešci ϵ_t na ponderisanom skupu. U ovoj implementaciji, slabi klasifikator je "panj" (decision stump, `max_depth=1`) – stablo koje pravi odluku na osnovu samo jednog atributa i jednog praga, uz `n_estimators=100` i `learning_rate=0.5`.

Nad svim atributima AdaBoost ostvaruje Accuracy od svega **74.40%** (precision 0.7608, recall 0.7440, F1 0.7502), a nad PCA skupom **71.35%** (precision 0.7167, recall 0.7135, F1 0.7139) – najniže performanse od svih pet algoritama, na oba skupa podataka.


Razlog slabijih performansi leži u samoj prirodi algoritma: svako od 100 stabala pravi odluku na osnovu samo jednog atributa i jednog praga. Iako ansambl sekvencijalno ispravlja greške prethodnih klasifikatora (fokusravajući se sve više na pogrešno klasifikovane uzorke), suma jednostavnih linearnih granica po jednoj promenljivoj teško može da uhvati složene, nelinearne i međusobno zavisne odnose između karakteristika i tipa aktivnosti. Zato AdaBoost sa plitkim panjevima zaostaje kako za Random Forest-om (koji koristi mnogo dublja, ekspresivnija stabla, `max_depth=10`), tako i za SVM-om sa Gausovim jezgrom.

3.5 XGBoost algoritam

XGBoost (Extreme Gradient Boosting) je boosting algoritam, ali umesto ponderisanja pogrešno klasifikovanih uzoraka, on gradi svako naredno stablo tako da minimizuje regularizovanu gubitak-funkciju preko gradijentnog spusta. Sadrži eksplicitni regularizacioni član koji kažnjava kompleksnost stabla, čime se direktno sprečava preprilagođavanje – za razliku od AdaBoost-a, koji nema eksplicitnu regularizaciju ovog tipa. Korišćeni hiperparametri su `n_estimators=200`, `max_depth=4`, `learning_rate=0.05`, uz `subsample=0.8` i `colsample_bytree=0.8` (svako stablo

se trenira na 80% nasumično izabranih uzoraka i 80% nasumično izabranih atributa), što unosi dodatnu nasumičnost i dodatno smanjuje rizik od preprilagođavanja.

Rezultati pokazuju da je XGBoost ostvario najveće performanse od svih pet algoritama na skupu sa svim prediktorima – Accuracy od **98.88%** (precision 0.9889, recall 0.9888, F1 0.9888). Nakon primene PCA uočava se pad performansi na **88.39%** (precision 0.8853, recall 0.8839, F1 0.8843), ali model i dalje zadržava viši nivo tačnosti od Random Forest-a nad istim (PCA) skupom (87.20%).




Slika 6: Matrice konfuzije za XGBoost – nad svim atributima (levo) i nakon PCA (desno).

Zbog izuzetno visoke tačnosti (98.88%), koja može da zavarava usled preprilagođavanja ili čurenja informacija o ispitaniku kroz slučajnu podelu na trening/test skup, sprovedena je dodatna provera unakrsnom validacijom, sa nasumičnim mešanjem podataka pre deljenja na foldove, (`shuffle=True`). Bez mešanja, uzorci istog ispitanika ostaju skoncentrisani unutar pojedinačnih foldova (jer su redosledno upisivani u originalnom fajlu), čime bi se dobila znatno niža procena performansi – to jest, model bi morao da generalizuje na potpuno nove ispitanike, što je teži i realističniji zadatak. Nasumičnim mešanjem pre deljenja na foldove obezbeđuje se da svaki fold sadrži reprezentativan, nasumičan uzorak iz celog skupa podataka (uključujući uzorke od svih 40 ispitanika u svakom foldu), čime se dobija procena uporediva sa onom koju daje originalni `train_test_split`. Dobijeni rezultati unakrsne validacije (`[0.984, 0.989, 0.990, 0.980, 0.979]`, prosek **98.44%**) konzistentni su kroz sve foldove i vrlo bliski tačnosti dobijenoj na originalnom test skupu, uz izuzetno malo odstupanje (standardna devijacija reda veličine 0.004). Ovo potvrđuje da se model ne preprilagođava – visoka tačnost je stabilna nezavisno od toga koji konkretni uzorci se nađu u trening, a koji u test skupu.

XGBoost koristi dublja stabla (`max_depth=4`) u kombinaciji sa regularizacijom (`subsample` i `colsample_bytree` < 1), pa uspeva da uhvati složenije nelinearne i međusobno zavisne odnose bez prekomernog prilagođavanja. Ovo XGBoost čini ubedljivo najboljim modelom u ovoj analizi, kako po tačnosti tako i po robusnosti na redukciju dimenzionalnosti.

Značajnost prediktora (feature importance). Dodatno je analiziran grafik značajnosti atributa za XGBoost model (po kriterijumu *gain* – prosečno smanjenje gubitka koje atribut donosi kada se koristi za podelu čvora), prikazan na Slici 7.



Slika 7: XGBoost feature importance (kriterijum gain) – 20 najznačajnijih atributa nad skupom svih prediktora.

Grafik pokazuje da XGBoost ne koristi sve atribute podjednako – najveći doprinos klasifikaciji imaju određene karakteristike, dok je uticaj ostalih znatno manji. To ukazuje da model najveći deo odluka zasniva na ograničenom broju najinformativnijih karakteristika, koje prema kriterijumu gain ostvaruju najveće smanjenje greške prilikom izgradnje stabala odlučivanja.

Vredi primetiti i razliku u odnosu na PCA analizu iz prethodne sekcije: PC1 je bila određena ECG karakteristikama varijabilnosti srčanog ritma, dok XGBoost feature importance (koja *jeste* nadgledana) takođe ističe karakteristike vezane za HRV i EDA amplitudu kao najdiskriminativnije – što sugerise da se u ovom konkretnom slučaju pravac najveće varijanse delimično poklapa sa pravcem najveće diskriminativnosti.

Generalno, PCA redukcija dosledno smanjuje performanse svih modela (jer se odbacuje ~5% varijanse koja očigledno nosi diskriminativnu informaciju, naročito za razgraničenje mentalne i emocionalne aktivnosti), ali je taj efekat znatno izraženiji kod modela zasnovanih na stablima nego kod linearnih/margin modela.

4 Klasterovanje

Za klasterovanje korišćeni su sledeći algoritmi: **KMeans++** i **Hierarchical (Agglomerative) clustering** kao centroidne metode koje zahtevaju unapred zadati broj klastera; **GMM (Gaussian Mixture Model)** kao probabilistička metoda i **DBSCAN** i **HDBSCAN** kao metode zasnovane na gustini, koje broj klastera određuju automatski. Kako target promenljiva ima 4 klase, testirane su vrednosti broja klastera $k \in \{2, 3, 4, 5, 6\}$ za KMeans++ i Hierarchical, kao i analogan opseg broja komponenti za GMM, kako bi se proverilo da li podaci "prirodno" formiraju baš 4 klastera. Svaki algoritam je pušten preko više kombinacija hiperparametara, a za svaku kombinaciju izračunate su tri evaluacione metrike, čime se dobija potpunija slika nego oslanjanjem na jednu, unapred izabranu konfiguraciju. Klasterovanje je izvršeno najpre nad celim standardizovanim skupom (533 atributa), a zatim i nad PCA skupom (61 komponenta), radi poređenja.

Evaluacione metrike. Kako klasterovanje nema pristup pravim oznakama (Activity se ovde ne koristi kao target, već isključivo za naknadnu vizuelnu proveru), kvalitet klastera se procenjuje unutrašnjim metrikama:

- **Silhouette koeficijent** za tačku i definiše se kao $s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$, gde je $a(i)$ prosečno rastojanje tačke i od ostalih tačaka u istom klasteru, a $b(i)$ najmanje prosečno rastojanje do tačaka nekog drugog (najbližeg) klastera. Vrednosti su u opsegu $[-1, 1]$, pri čemu vrednosti bliske 1 znače da je tačka mnogo bliža sopstvenom klasteru nego bilo kom drugom.
- **Calinski-Harabasz indeks** predstavlja odnos disperzije između klastera (B) i disperzije unutar klastera (W), normalizovan brojem klastera i uzoraka: $CH = \frac{\text{tr}(B)}{(K-1)\text{tr}(W)/(n-K)}$. Veće vrednosti ukazuju na kompaktnije, bolje razdvojene klustere.

- **Davies-Bouldin indeks** računa, za svaki par klastera i, j , odnos zbira njihovih unutrašnjih rasipanja σ_i, σ_j i rastojanja između njihovih centara $d(c_i, c_j)$: $DB = 1/K \sum_i \max_{j \neq i} \sigma_i + \sigma_j d(c_i, c_j)$. Manje vrednosti su bolje, jer ukazuju da su klasteri međusobno udaljeni u odnosu na sopstvenu unutrašnju disperziju.

4.1 Rezultati nad svim atributima

Tabela 1: Deset najboljih konfiguracija po Silhouette koeficijentu – skup svih 533 (standardizovanih) atributa.

Familija	Konfiguracija	Silhouette	CH	DB
KMeans++	$k = 2$	0.3203	663.82	2.152
GMM	$n = 3$, cov=tied	0.3181	582.02	1.565
KMeans++	$k = 3$	0.3015	610.22	1.751
GMM	$n = 4$, cov=tied	0.3007	581.44	1.476
KMeans++	$k = 4$	0.2986	633.28	1.397
KMeans++	$k = 5$	0.2974	640.42	1.161
GMM	$n = 3$, cov=full	0.2623	550.64	1.627
Hierarchical	$k = 4$, ward	0.2608	563.17	1.628
Hierarchical	$k = 5$, ward	0.2608	579.47	1.372
GMM	$n = 5$, cov=tied	0.2504	578.67	1.630


Konfiguracija `kmeans_pp` ($k=2$) ostvaruje najveći Silhouette (0.3203) i CH indeks (663.82), ali istovremeno i najgori DB indeks (2.152) u celoj tabeli – ova naizgled kontradiktorna kombinacija sugerise da je podela na samo dva klastera previše gruba, jer model spaja podklasterne koji bi mogli biti razdvojeni.

GMM konfiguracije sa `covariance=tied` ($n = 3$: Silhouette 0.3181; $n = 4$: 0.3007) postižu Silhouette na nivou najboljeg KMeans rezultata, ali uz znatno bolji DB (1.565 i 1.476). Obrazac je dosledan – `tied` kovarijansa konzistentno nadmašuje `full` na istom broju komponenti (npr. $n = 3$: 0.3181 naspram 0.2623), jer zajednički oblik kovarijanse bolje generalizuje u visokoj dimenzionalnosti, dok `full` lakše prilagođava šumovitim podklasterima.

Hierarchical (`ward`) sa $k = 4$ i $k = 5$ daje identičan Silhouette (0.2608), što ukazuje da peti klaster nastaje cepanjem jednog od postojeća četiri, a ne otkrivanjem nove strukture. Kod GMM familije Silhouette dosledno opada sa porastom broja komponenti ($0.3181 \rightarrow 0.3007 \rightarrow 0.2504 \rightarrow 0.2457$) – tipičan znak prekomerne segmentacije.

DBSCAN se ne nalazi ni u prvih 20 konfiguracija, a HDBSCAN je pri dnu (Silhouette ≈ 0.055 – 0.057 , svega 2 klastera). Density-based algoritmi očigledno ne uspevaju da izdvoje klasterne na ovom skupu, za razliku od centroid-based i probablističkih metoda.

Zašto density-based metode ovde ne uspevaju: DBSCAN i HDBSCAN se oslanjaju na koncept lokalne gustine, definisan preko broja suseda u kugli poluprečnika ε (DBSCAN), odnosno preko hijerarhijske stabilnosti gustine (HDBSCAN). U prostoru visokih dimenzija, poznat je fenomen *koncentracije rastojanja* (distance concentration): za slučajne tačke u p -dimenzionom prostoru, odnos $\frac{d_{\max} - d_{\min}}{d_{\min}}$ između najveće i najmanje udaljenosti do ostalih tačaka teži nuli kako $p \rightarrow \infty$ – drugim rečima, sve tačke postaju približno jednako udaljene jedna od druge, pa koncept "gustog regiona odvojenog retkim regionom" gubi geometrijski smisao. Kako skup sadrži veliki broj međusobno korelisanih prediktora, lokalnu gustinu postaje teško razlikovati čak i posle standardizacije, što otežava formiranje klastera primenom DBSCAN i HDBSCAN algoritma. Sa druge strane, KMeans++ i Hierarchical (`ward`) uspešno identifikuju grupe oko svojih centroida, jer centroidne metode ne zahtevaju postojanje "praznina" u gustini, već samo relativnu blizinu tačaka svom najbližem centru – ovo ukazuje da podaci imaju kontinuiranu, globularnu/eliptičnu strukturu bez oštih granica između grupa, koja više odgovara centroidnim i probablističkim nego gustinskim metodama klasterizacije.




Slika 8: UMAP vizuelizacija najbolje konfiguracije za svaku od pet familija algoritama, nad svim atributima.

Na UMAP vizuelizaciji (Slika 8) jasno se vidi da centroidne i probabilističke metode formiraju kompaktne, prostorno odvojene grupe, dok gustinski zasnovane metode (DBSCAN, HDBSCAN) formiraju ili jedan ogroman klaster uz mnoštvo tačaka klasifikovanih kao šum, ili nepravilne, izmešane grupe koje ne prate vizuelno uočljivu geometrijsku strukturu podataka.

4.2 Rezultati nad PCA skupom i poređenje

Tabela 2: Deset najboljih konfiguracija po Silhouette koeficijentu – skup PCA komponenti (61 komponenta).

Familija	Konfiguracija	Silhouette	CH	DB
GMM	$n = 3$, cov=tied	0.3428	618.66	1.508
GMM	$n = 4$, cov=tied	0.3423	599.85	1.213
KMeans++	$k = 2$	0.3330	703.30	2.074
KMeans++	$k = 3$	0.3180	650.78	1.693
KMeans++	$k = 4$	0.3180	680.51	1.345
GMM	$n = 5$, cov=tied	0.3173	606.19	1.206
KMeans++	$k = 5$	0.3137	693.70	1.134
Hierarchical	$k = 4$, ward	0.2806	594.26	1.559
Hierarchical	$k = 5$, ward	0.2806	617.43	1.315
GMM	$n = 6$, cov=tied	0.2697	598.89	1.318



Slika 9: UMAP vizuelizacija najbolje konfiguracije za svaku od pet familija algoritama, nad PCA skupom prediktora.

Poredeći najbolji Silhouette indeks po familiji algoritma na oba skupa (Tabela 1 naspram Tabele 2), uočava se da klasterovanje nad PCA skupom daje nešto viši Silhouette indeks za KMeans++ (0.3330 naspram 0.3203), Hierarchical clustering (0.2806 naspram 0.2608), i posebno za GMM sa tied kovarijansom (0.3428 naspram 0.3181, gde GMM-tied($n = 3$) sada postaje *apsolutno najbolja* konfiguracija u celoj tabeli, nadmašujući čak i KMeans++. Ovo je suprotno od onoga što je uočeno kod klasifikacije.

Razlog je sledeći: klasterovanje ne koristi informaciju o ciljnoj promenljivoj, već se oslanja isključivo na geometriju rastojanja između tačaka u prostoru prediktora, a PCA upravo optimizuje taj prostor tako da su najvažniji pravci varijabilnosti istaknuti, dok se šum i redundantne, međusobno

visoko korelisane dimenzije uklanjaju. Manje, "gušće" PCA reprezentacije olakšavaju centroidnim i probabilističkim algoritmima da pronađu kompaktnije i bolje razdvojene klastere – jer u prostoru manje dimenzionalnosti euklidsko rastojanje bolje odražava stvarnu geometrijsku blizinu tačaka, dok se u originalnom prostoru od 533 dimenzije "razblažuje" istim fenomenom koncentracije rastojanja pomenutim ranije. Kod klasifikacije, međutim, PCA može odbaciti baš one dimenzije koje su ključne za razgraničenje određenih, fiziološki sličnih klasa (klase 2 i 3) – što objašnjava zašto isti postupak redukcije dimenzionalnosti ima suprotan efekat na dva različita zadatka.

DBSCAN i HDBSCAN ni nakon PCA redukcije nisu uspjeli da identifikuju stabilne klastere (Silhouette ≈ 0.073 – 0.076), što ukazuje da podaci ni nakon redukcije dimenzionalnosti ne poseduju dovoljno izraženu lokalnu gustinu za njihovu uspešnu primenu – razlike između centroidnih i gustinskih metoda postaju, ako išta, još izraženije nakon PCA.

4.3 Zaključak

Nijedna metrika samostalno ne daje jednoznačnog "pobednika" jer se rezultati KMeans ($k=2$) i GMM (tied kovarijansa) razlikuju u zavisnosti od kriterijuma:

- Za **maksimalnu geometrijsku separaciju** (bez obzira na fino granularnu strukturu) – najbolji izbor nad svim atributima je **KMeans++ ($k=2$)**, dok je nad PCA skupom to i dalje konkurentno GMM-u.
- Za **balansiran rezultat** koji istovremeno postiže dobru separaciju i nisku unutar-klastersku disperziju (dobar Silhouette/CH i dobar DB) – **GMM ($n_components=3$ ili 4 , covariance=tied)** predstavlja optimalan kompromis na oba skupa podataka, a nad PCA skupom čak postaje i apsolutno najbolja konfiguracija.

Na osnovu svih evaluacionih metrika može se generalno zaključiti da centroidne i probabilističke metode (KMeans++, Hierarchical, GMM) daju konzistentno bolje i međusobno slične rezultate, dok algoritmi zasnovani na gustini (DBSCAN, HDBSCAN) nisu bili uspešni ni na jednom od dva skupa podataka, što se objašnjava velikom (efektivnom) dimenzionalnošću i karakteristikama skupa podataka koje ne poseduju jasno izražene regione različite gustine. Takođe je zanimljivo da nijedna konfiguracija sa brojem klastera $K = 4$ (koji odgovara stvarnom broju klasa Activity) nije nadmašila konfiguracije sa manjim brojem klastera ($K = 2$ ili $K = 3$) po Silhouette kriterijumu – ovo je u potpunosti u skladu sa ranijom t-SNE vizuelizacijom, gde su se klase 2 i 3 (mentalna i emocionalna aktivnost) toliko preklapale da ih nenadgledani algoritam prirodno tretira kao jednu grupu.

5 Pravila pridruživanja

Za analizu pravila pridruživanja implementirane su dve metode – **Apriori** i **FP-Growth** algoritam – nad prediktorima dobijenim **Pirsonovim filterom** (103 atributa). PCA komponente su apstraktne linearne kombinacije originalnih atributa i nemaju direktno fiziološko značenje, pa bi pravilo tipa $PC_5_low \rightarrow Activity_4$ bilo teško protumačiti u kontekstu stvarnih fizioloških signala. Nasuprot tome, Pirsonov filter samo uklanja redundantne attribute i zadržava originalna imena preostalih, pa pravila pridruživanja dobijena nad ovim skupom mogu direktno da se protumače.

Kako su pravila pridruživanja definisana nad kategoričkim podacima, svaki numerički atribut je diskretizovan u tri kategorije (**low**, **medium**, **high**) preko kvantila ($q = 3$, funkcija `pd.qcut`), čime se svaki uzorak prevodi u "korpu" binarnih stavki pogodnu za algoritme pretrage čestih skupova.

Korišćene su tri mere kojim su se analizirali rezultati primene algoritama: Support, Lift i Confidence. Support meri koliko je pravilo često (udeo transakcija u kojima se antecedent i konsekvant javljaju zajedno).

Confidence meri uslovnu verovatnoću konsekvanta datog antecedenta.

Lift meri koliko je jače pravilo od onoga što bi se očekivalo pri statističkoj nezavisnosti antecedenta i konsekvanta – vrednost $lift = 1$ znači nezavisnost, $lift > 1$ znači pozitivnu asocijaciju, a $lift < 1$ negativnu.

Apriori algoritam koristi princip monotonosti (švaki podskup čestog skupa mora i sam biti čest) da bi generisao kandidate za česte skupove nivo po nivo, eksplicitno generišući i proveravajući kandidate rastuće veličine. **FP-Growth** umesto generisanja kandidata gradi kompresovanu strukturu podataka (FP-stablo, prefiksno stablo transakcija sortiranih po učestalosti stavki) i rekurzivno izdvaja česte skupove kroz uslovne pod-baze, bez eksplicitnog generisanja i provere kandidata – što ga čini računarski efikasnijim na velikim skupovima podataka, iako oba algoritma, pri identičnim pragovima za support, u teoriji pronalaze potpuno isti skup čestih proizvoda.

Za filtriranje pravila korišćeni su pragovi $support \geq 0.10$, $confidence \geq 0.70$ i $lift \geq 1.50$, kako bi se izdvojila samo pravila koja se javljaju dovoljno često, imaju visoku pouzdanost i predstavljaju statistički značajnu povezanost između stavki.

5.1 Apriori algoritam

Primenom Apriori algoritma nad Pirsonovim skupom prediktora generisano je i filtrirano **265 pravila** koja zadovoljavaju zadate pragove. Ova pravila su, međutim, dominantno feature-feature veze – na primer, pravila poput $IT_PSD_mean_medium \leftrightarrow IT_VLF_std_medium$ ostvaruju support 0.328 i **confidence tačno** 1.000 (savršena pouzdanost), sa lift-om ≈ 3.05 . Ovakva pravila, iako statistički besprekorna, predstavljaju trivijalno očekivan nalaz: reč je o karakteristikama izvedenim iz istog signala (IT – torakalna bioimpedanca).

Da bi se izdvojila pravila relevantna za sam cilj analize (predikciju tipa aktivnosti), dodatno je filtrirano da konsekvant skupa uslova sadrži klasu aktivnosti (*Activity_i*). Ovim filtriranjem izdvojeno je **5 pravila** sa Activity kao konsekvantom:

Tabela 3: Pravila pridruživanja (Apriori) sa klasom Activity kao konsekvantom.

Antecedent	Konsekvant	Support	Confidence	Lift
IT_Original_std_high	Activity_4	0.2453	0.7356	2.942
IT_BRV_skewness_high	Activity_1	0.0217	0.9798	3.919
IT_VLF_skewness_medium	Activity_1	0.0283	0.9845	3.938
IT_MF_kurtosis_medium	Activity_1	0.0109	0.9800	3.920
IT_p_Total_skewness_medium	Activity_1	0.0176	0.9753	3.901

Pravilo $IT_Original_std_high \rightarrow Activity_4$ ima najveći support (0.2453), uz confidence od 0.7356 i lift 2.942. Atribut $IT_Original_std_high$ označava visoku standardnu devijaciju originalnog signala torakalne električne bioimpedance (IT), odnosno izraženu varijabilnost signala. Takav obrazac ukazuje da se tokom *Activity_4* (fizička aktivnost) beleže veće oscilacije u respiratornom/bioimpedantnom signalu, što je fiziološki očekivano za fizički intenzivnije aktivnosti kod kojih dolazi do izraženih promena u dubini i ritmu disanja. Najveći support ovog pravila (u odnosu na preostala četiri) pokazuje da je upravo povećana varijabilnost IT signala najčešće prisutna karakteristika baš ove klase aktivnosti – ono se javlja kod skoro čitave klase 4 (support $0.2453 \approx 1120/4480 \approx 0.25$).

Preostala četiri pravila povezuju attribute **skewness** i **kurtosis** signala IT_BRV, IT_VLF, IT_MF i IT_p_Total sa klasom *Activity_1*. Za razliku od standardne devijacije (koja meri *rasipanje* signala), $skewness = E[(X - \mu)^3]/\sigma^3$ meri asimetriju raspodele oko srednje vrednosti, dok $kurtosis = E[(X - \mu)^4]/\sigma^4$ opisuje "težinu repova" raspodele (koliko su ekstremne vrednosti izražene u odnosu na normalnu raspodelu, za koju je kurtosis = 3). Ovi atributi, dakle, ne opisuju intenzitet/amplitudu signala, već *oblik* njegove raspodele tokom vremenskog prozora merenja. Izuzetno visoke vrednosti confidence-a (0.975–0.985) i lift-a (3.90–3.94) ukazuju da se ovakvi obrasci gotovo isključivo javljaju kod aktivnosti *Activity_1* (neutralna, aktivnost odmora).

Ovi rezultati sugerišu fiziološki smisleni razliku u prirodi dva tipa aktivnosti: *Activity_1* (odmor) je prepoznatljiva po specifičnoj *strukturi i obliku raspodele* respiratornog signala (blaga, ali dosledna asimetrija i "težina repova" u mirovanju), dok je *Activity_4* (fizička aktivnost) prvenstveno karakterisana povećanom *varijabilnošću (amplitudom)* signala, odnosno izraženijim promenama u respiratornoj aktivnosti usled fizičkog napora.

5.2 FP-Growth algoritam

FP-Growth algoritam je nad istim skupom podataka i istim pragovima identifikovao **265 filtriranih pravila** ukupno – identičan skup kao i Apriori, što je i teorijski očekivano, budući da oba algoritma pronalaze iste česte skupove stavki.

Nakon filtriranja pravila tako da konsekvant predstavlja klasu aktivnosti, FP-Growth je izdvojio samo **jedno** pravilo koje zadovoljava zadate pragove: $IT_Original_std_high \rightarrow Activity_4$ (support = 0.2453, confidence = 0.7356, lift = 2.942) – identično prvom pravilu dobijenom Apriori algoritmom, i identičnom zaključku da je povećana standardna devijacija originalnog signala torakalne električne bioimpedance karakteristična za fizičku aktivnost.

Sa druge strane, posmatrajući sva generisana pravila (ne samo ona sa Activity konsekvantom), može se uočiti da se najveći broj njih odnosi na međusobne veze između izvedenih prediktora, posebno onih koji potiču iz istog fiziološkog signala (npr. IT_PSD_mean, IT_VLF_std, IT_BRV_std). Međutim, ova pravila ne pružaju dodatne informacije o zavisnosti između prediktora i ciljne promenljive, zbog čega nisu od značaja za interpretaciju klasifikacionog problema, i zahtevaju eksplicitno filtriranje po konsekvantu da bi se iz ukupnog skupa pravila izdvojio deo relevantan za razumevanje strukture aktivnosti.

6 Zaključak

Sveobuhvatna analiza ovog skupa fizioloških podataka – kroz klasifikaciju, klasterovanje i pravila pridruživanja – konzistentno potvrđuje jednu centralnu činjenicu o samoj prirodi podataka: od 533 formalno različitih prediktora, veliki deo predstavlja redundantne, međusobno visoko korelisane transformacije svega tri osnovna fiziološka signala (ECG, torakalna bioimpedanca i EDA). Ova redundantnost je nezavisno potvrđena sa tri različita ugla: Pirsonovim filterom (430 od 533 atributa odbačeno zbog korelacije > 0.8), PCA analizom (61 komponenta dovoljna za 95% varijanse, uz loading-e koji pokazuju da su prve komponente određene gotovo isključivo jednim tipom signala) i pravilima pridruživanja (feature-feature pravila sa confidence = 1.000 između srodnih IT karakteristika).

Uprkos ovoj redundantnosti, XGBoost postiže gotovo savršenu klasifikaciju (98.88% tačnosti, potvrđeno unakrsnom validacijom), zahvaljujući kombinaciji dovoljno ekspresivnih stabala i eksplicitne regularizacije koja mu omogućava da efikasno izdvoji mali broj zaista diskriminativnih atributa. Klasterovanje pokazuje suprotan, ali komplementaran nalaz: nenadgledani algoritmi prirodno grupišu podatke u 2–3 geometrijske celine (a ne u 4, koliko ima stvarnih klasa aktivnosti), jer klase mentalne i emocionalne aktivnosti fiziološki toliko liče jedna na drugu da ih je nemoguće razdvojiti bez informacije o samoj nameni eksperimenta. Konačno, pravila pridruživanja, nakon filtriranja trivijalnih feature-feature veza, otkrivaju fiziološki smislenu i interpretabilnu razliku: fizička aktivnost karakteriše se povećanom *varijabilnošću* respiratornog signala, dok je stanje mirovanja prepoznatljivo po specifičnom *obliku raspodele* istog signala – dva različita, ali komplementarna statistička opisa fiziologije napora naspram fiziologije mirovanja.